시계열 데이터 추론 실습 최종 결과 보고서 (2팀)

Oct 22, 2026 · @김채림

1. 데이터 수집 체계

확인 기준: ① 상시 수집, 설정만 바꿔 새 형식 대응 ② 브로커·네트워크·보드 재부팅 뒤 자동 복구(1분 안) ③ 24시간 커버율 95% 이상, 빠진 구간의 원인 설명 → **충족** (커버율 99.4~99.9%, 낮은 곳은 센서 주기로 설명)

MQTT 수집기를 젯슨에 상시 서비스로 돌려 60개 공간·항목을 모았고, 재부팅·네트워크 끊김 뒤에도 사람 손 없이 복구해 데이터를 잃지 않았다. 저장은 젯슨 SQLite(원본·전송 대기열) → PostgreSQL이고, 학교 InfluxDB는 읽기 전용이다.

요구사항	결과
상시 수집·현황 보기	18시간 무인 가동(이후 계속), 전송 대기 0건, `status.py` 로 건수·마지막 수신·커버율
설정만 바꿔 새 형식 대응	config.yaml 규칙 12줄 추가 → 미분류 23 → 5건, 코드 변경 없음
자동 복구	재부팅 1분 내 재시작, 와이파이 60초 차단 → 15초 만에 재접속·무손실
(심화) 중복·보관	재전송 468건 제거(devEui+fCnt+날짜) / 1년 15.4GB → 원본 30일·10분 집계 1년·1시간 영구로 2.9GB

공간	항목 수	전송 주기	커버율	판정
실습실	13	60~330초	99.4~99.9%	정상
사무실·사무실 밖	6	60초	99.6~99.9%	정상
대표실·컨트롤러·집중회의실	22	60초	99.7~99.8%	정상
회의실	3	600초	9.9%	센서가 10분마다 보내 정상
개발실 실내기·실외기	16	63~85초	68.7~68.8%	기기가 약 85초마다 전송

측정 조건 — 실데이터, 2026-10-20 15:46 ~ 10-21 10:02(약 18시간), 학교 브로커 전체 토픽 QoS 1. 커버율 = 지나간 1분 칸 중 데이터가 있는 칸의 비율. 재부팅 시험 10-20 17:28, 네트워크 차단 17:34~17:35. 용량은 10-21 11:03 기준 19.3시간 75,323행에서 추정. 젯슨 Orin Nano, 25W.

해석: 비어 보이는 데이터의 원인은 수집기가 아니라 센서 주기였다(회의실 10분, 개발실 85초). 그래서 커버율은 센서별 기대 주기로 판정해야 한다. LoRa 게이트웨이 시계가 약 5분 빨라 센서 시각(`time`) 대신 네트워크 서버 수신 시각(`nsTime`)을 쓴다. 브로커 재시작은 학교 서버라 직접 시험하지 못했고, 같은 재접속 경로를 네트워크 차단으로 확인했다.

2. 데이터 이해와 기준선

확인 기준: ① 정규화 값은 학습 기간만으로 계산 ② 기준선과 모델을 같은 시점·같은 조건에서 평가 ③ 세 기준선 중 가장 강한 것과 그 이유 → **충족** (현재값 유지 최강, 모델과 같은 창에서 41.0ppm)

세 기준선 중 "현재값 유지"가 모든 공간·지평에서 가장 강했다(60분 뒤 CO2 41.0ppm). 7주 실데이터에서 수업·점심·퇴실이 뚜렷하게 보였고, CO2는 일정 변화 뒤 5~8분 만에 반응했다. 단, 시간표는 수업의 약 12%에서 실제와 달랐다.

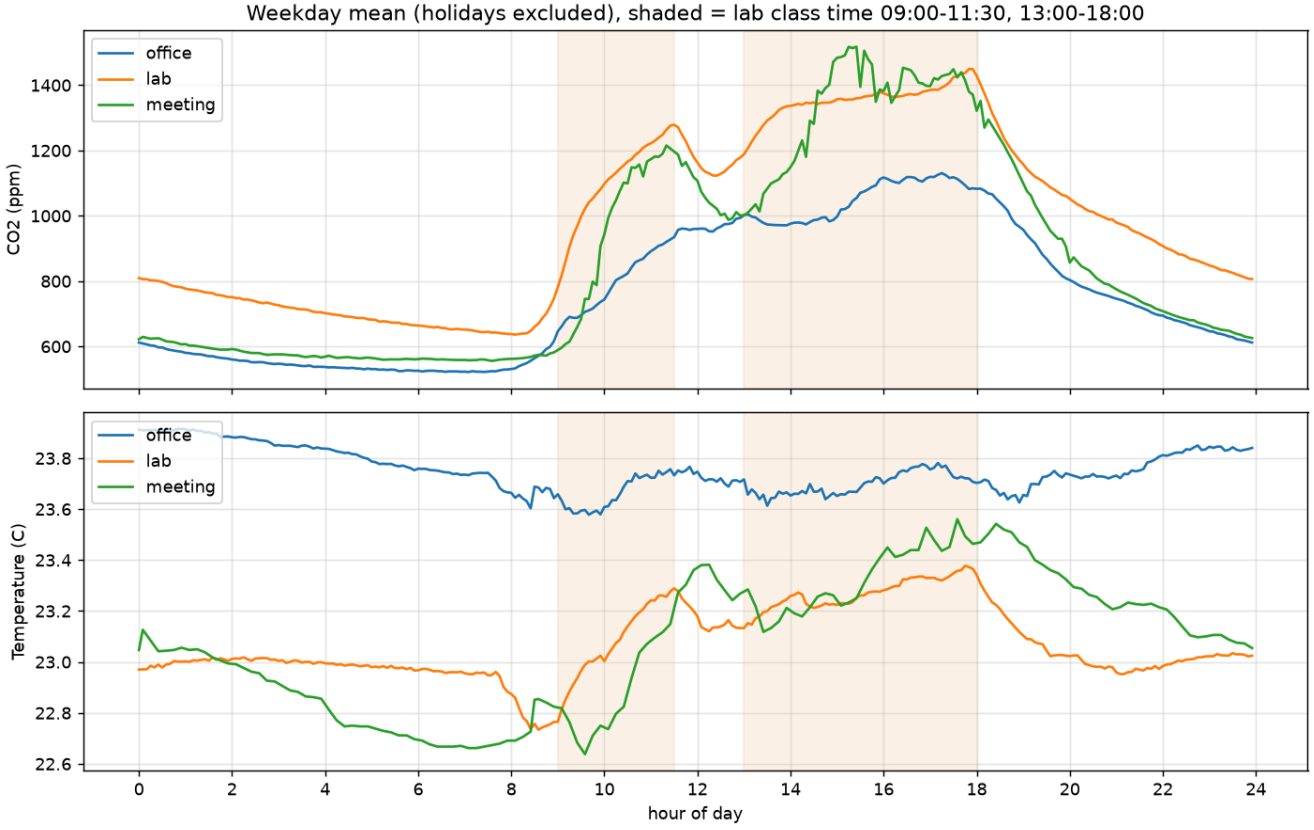


그림 2-1. 평일(공휴일 제외) 5분 단위 평균. 실습실(lab) CO2는 9시 급등 → 11:30 점심 하락 → 13시 재상승 → 18시 이후 감소. 평균만으로도 10~19시에 1,000ppm을 넘는다. 온도 변화는 하루 0.5 ℃ 안팎. 실데이터 2026-09-01~10-22.

기준선	5분	15분	30분	60분 CO2	60분 온도	60분 CO2 실습실 / 회의실
현재값 유지	**8.6**	**15.5**	**24.1**	**41.0**	**0.106°C**	41.9 / 37.5
최근 1시간 평균	23.1	28.9	37.4	53.5	0.146°C	54.6 / 47.1
어제 같은 시각	112.0	112.2	112.5	113.5	0.538°C	77.0 / 146.7

측정 조건 — 실데이터(학교 InfluxDB) 2026-09-01~10-22 08:28(51.4일), 461,181행(1분 평균), 실습실·사무실·회의실. 시험 10-14~21, 평가점 6,477개(실습실 수업 시간 540개, 현재값 유지 81.7ppm). CO2 MAE(ppm). 모델(3장)과 같은 창·같은 정제·같은 시점. 정규화는 학습 기간(09-01~10-06)만으로 계산(CO2 평균 794.7, 표준편차 491.1). 젯슨 25W.

일정 변화 (실습실, 각 33회)	±30ppm까지 걸린 시간 (중앙값, 25~75%)	60분 변화	반응 없음
09:00 수업 시작	5.5분 (4~6)	+293ppm	3회
13:00 수업 시작	6분 (4~16)	+140ppm	4회
11:30 점심	8분 (3.5~12.5)	−177ppm	5회
18:00 퇴실	6분 (4~11)	−243ppm	2회

정제·분할 규칙: ① 불가능한 값(CO2 350~5,000, 온도 5~40℃, 습도 5~100% 밖) 제거 — 51일간 0건. ② 한 칸만 CO2 300ppm·온도 3℃ 뛰었다 돌아오는 튄 값 제거 — 회의실 CO2 34개(0.46%)만. ③ 결측은 CO2 10분·온습도 30분까지 보간, 그 이상은 비움 — 수신률(센서 주기 기준) 98.6~99.4%, 1시간 넘는 결측 0번. ④ 1분·10분 센서를 5분 평균으로 맞춤 — 잡음 9.4 → 5.8ppm, 반응(5~8분) 보존. ⑤ 시간순 분할, 입력부터 정답까지 한 구간 안 — 이웃 칸 상관 0.997이라 무작위로 섞으면 오차가 8.3ppm으로 부풀려진다(실제 52.1).

측정 조건 — 정제 결과는 위와 같은 51일 실데이터. 잡음(9.4 → 5.8ppm)과 무작위 분할 실험(8.3 vs 52.1ppm)은 초기 실데이터 2026-10-20 15:46~10-21 13:01(21.2시간, 실습실 CO2, 5분 평균)에서 측정. 젯슨 25W.

- **현재값 유지가 강한 이유:** 5분 뒤 값과 상관이 0.997이다. '어제 같은 시각'은 지금 값을 쓰지 않아 가장 약하고, 일과가 고정된 실습실(77)에서만 덜 나쁘다.
- **일정과 어긋난 날:** 수업 66회 중 8회는 CO2가 50ppm도 오르지 않았고(9/28~30 집중), 수업 없는 주말 6일은 150ppm 넘게 올랐다. 이 12%가 3장에서 실데이터 이득이 작은 이유다.

3. 60분 예측

확인 기준: 같은 시점에서 기준선(현재값 유지)보다 60분 예측이 정확할 것 → **충족** (CO2 합성 16.0 vs 39.2ppm, 실데이터 34.5 vs 40.8ppm)

시간표를 미래 입력으로 넣은 GRU가 기준선을 이겼다. 합성 데이터에서는 오차를 59% 줄였지만 실데이터에서는 15%였고, 그 이득은 시간표가 있는 실습실(48%)에 몰려 있다. 실데이터는 젯슨을 학교 유선망에 연결해 학교 InfluxDB의 2학기 데이터(09-01~10-22)를 받아 같은 코드로 다시 학습했다.

모델 (60분 뒤)	합성 CO2	합성 온도	실데이터 CO2	실데이터 온도
GRU	**16.0**	**0.047**	34.5	0.115

모델 (60분 뒤)	합성 CO2	합성 온도	실데이터 CO2	실데이터 온도
LSTM	16.7	—	36.4	0.105
TCN	16.9	—	**33.4**	0.120
GRU (시간표 제외)	23.8	—	38.0	0.106
현재값 유지	39.2	0.188	40.8	**0.105**
최근 1시간 평균	48.3	—	53.1	0.146
어제 같은 시각	55.3	—	109.5	0.537

측정 조건 — CO2 ppm, 온도 °C(MAE). 합성: 2026-09-21~10-18(4공간), 학습 09-21~10-04 / 검증 10-05~11 / 시험 10-12~18. 실데이터: 2026-09-01~10-22(3공간, 461,181행), 학습 09-01~10-06 / 검증 10-07~13 / 시험 10-14~21, 공휴일 제외. 입력 과거 2시간(5분×24칸), 세 기준선이 모두 있는 같은 시점만 평가. 젯슨 25W CPU 학습(합성 703초, 실데이터 334초). —: 미기록.

심화: 실데이터 60분 CO2	과거 60분	120분	240분	처음 보는 공간(회의실)
GRU	**34.1**	34.9	36.5	회의실 빼고 학습 37.1 / 포함 37.3
LSTM	35.5	37.1	35.7	—
TCN	**33.2**	33.9	34.0	—
현재값 유지	—	—	—	37.5

측정 조건 — 실데이터, 위와 같은 분할. 과거 길이 비교는 세 길이 모두에 있는 시점만, 시드 1개(차이 1~3ppm은 확정적이지 않음). 처음 보는 공간은 회의실 1,939점, 과거 120분, 두 모델 모두 공간 구분 입력 제거. 젯슨 25W.

- **원인:** CO2 변화는 사람의 출입이고, 출입을 미리 알려 주는 것은 시간표뿐이다. 실습실 수업 시간에서 시간표를 빼면 오차가 48.7 → 76.9ppm. 합성은 사람이 시간표대로만 움직여 이득을 4배 가까이 부풀렸다.
- **심화:** 과거는 1시간이면 충분하고(길면 배울 것만 늘어남), 처음 보는 공간에서도 나빠지지 않지만 이득도 없다. 이득은 공간이 아니라 일정에서 나온다.
- **행동:** 회의실 예약·근무 일정을 입력으로 확보하고, 그 전까지 일정 없는 공간과 60분 온도는 현재값 유지를 기본으로 둔다.

4. 이상 탐지

확인 기준: ① 모델과 규칙을 합쳐 이벤트 탐지율 80% 이상 ② 헛경보 하루 1회 이하 ③ 모델·규칙이 각각 못 잡는 고장과 이유 → **충족** (87%, 0.43회/일)

규칙과 모델을 합치자 고장 15건 중 13건(87%)을 잡았고 헛경보는 하루 0.43회였다. 어떤 방법도 혼자서는 60%를 넘지 못했다. 고장 종류마다 잡는 방법이 달랐기 때문이다. 경보 13건 중 12건은 원인 센서도 맞혔다.

방법	튄 값	값 고정	영점 틀어짐	냉방 정지	환기 정지	전체	평균 지연	헛경보/일
오토인코더	0/3	1/3	1/3	0/3	0/3	2/15	408분	0
(심화) 예측 오차 탐지기	0/3	0/3	1/3	**3/3**	1/3	5/15	151분	0.43
규칙 (튄 값·고정·범위)	**3/3**	**3/3**	0/3	0/3	0/3	6/15	0분	0
(심화) 규칙 + 새벽 기준선	3/3	3/3	**3/3**	0/3	0/3	9/15	167분	0
모두 결합	**3/3**	**3/3**	**3/3**	**3/3**	1/3	**13/15 (87%)**	132분	**0.43**

임계값 (검증 주에서 결정)	검증 헛경보/일	시험 탐지율	시험 헛경보/일
상위 1.00%	2.57	93%	1.71
상위 0.10%	0.00	87%	1.14
정상 최댓값 × 1.1 (선택)	**0.00**	**87%**	**0.43**

측정 조건 — 합성 데이터 2026-09-21~10-18(4공간). 학습 09-21~10-04(정상만), 임계값 결정 10-05~11(고장 없음), 시험 10-12~18(고장 5종 × 3건). 모델은 5분 평균, 규칙은 1분 원데이터. 모델 경보는 30분 이상 지속할 때만. 시험 주는 임계값 선택에 쓰지 않음. scikit-learn CPU, 젯슨 25W.

- **모델이 못 잡는 것(값 고정·튄 값):** 정상 범위 안에서 멈춘 값은 그럴듯하고 튄 값은 5분 평균에 묻힌다 → 규칙이 0~1분에 잡는다.
- **규칙이 못 잡는 것(냉방·환기 정지):** 천천히 그럴듯하게 변한다 → "이 시각·일정이면 얼마여야 하는지"를 아는 예측 오차 탐지기가 냉방 정지 3/3. 놓친 환기 정지 2건은 "사람이 많아서"와 구별이 안 됐다. 영점 틀어짐은 새벽 기준선으로 3/3, 대신 5~11시간 늦다.
- **임계값과 운영:** 검증 주 헛경보 0인 기준도 시험 주(더 추운 주)에는 하루 0.4~1.1회 → 계절마다 다시 잡는다. 튄 값·고정·범위는 센서 담당에게 즉시, 영점은 하루 1회 요약, 냉방·환기 정지는 시설 담당과 그 공간 수업 담당에게(30분 지속 시).

5. 상태 추정

확인 기준: ① 사용 여부: 직접 관찰 기준 정확도·F1과 빈 방→사용중 오류율, 단순 규칙보다 좋을 것 ② 환기 경보: 재현율 85% 이상, macro-F1이 규칙보다 높을 것 ③ 혼동 행렬과 가장 많이 헷갈리는 경우 → **충족** (F1 0.919 vs 0.546, 재현율 85.2%, macro-F1 0.796 vs 0.673)

사용 여부 분류기(F1 0.919)와 환기 선제 경보 분류기(재현율 85.2%, macro-F1 0.796) 모두 단순 규칙을 이겼다. 빈 방을 사용중으로 보는 오류(냉난방 자동 제어에서 가장 중요)는 0.0~0.5%다.

① 사용 여부 (직접 관찰 기준)	정확도	F1	빈 방→사용중 오류
단순 규칙 (15분 CO2 +30ppm)	94.8%	0.546	0.2%
분류기 (일정 정답으로 학습)	96.3%	0.705	0.0%
분류기 (관찰 정답으로 학습)	**98.7%**	**0.919**	0.5%
(시연) 일정을 입력에도 넣음	95.5%	0.663	0.8%

② 환기 선제 경보 (30분 안 1,000ppm)	정확도	정밀도	재현율	macro-F1
전부 "경보 없음"	99.1%	0%	0%	0.498
단순 규칙 (CO2 ≥ 850)	97.5%	23.5%	75.4%	0.673
분류기	98.9%	**46.0%**	**85.2%**	**0.796**

혼동 행렬 (5분 칸, 괄호는 규칙)	예측: 아니오	예측: 예
사용 여부 — 실제 비어있음	6,271 (6,260)	2 (13)
사용 여부 — 실제 사용중	253 (343)	304 (214)
환기 — 실제 필요 없음	6,511 (6,422)	61 (150)
환기 — 실제 곧 초과	9 (15)	52 (46)

측정 조건 — 합성 데이터 2026-09-21~10-18(4공간). 학습 09-21~10-04 / 검증 10-05~11 / 시험 10-12~18(6,830칸), 고장 구간과 회복 3시간 제외. "직접 관찰" = 합성 생성 때 저장한 실제 인원. 혼동 행렬의 사용 여부는 일정 정답 분류기. 환기 경보는 이미 1,000ppm 이상인 시점 제외, 양성 비율 시험 0.9%. HistGradientBoosting, 젯슨 25W CPU.

심화	결과
처음 보는 공간 F1	강의실A 0.925 · B 0.885 · 라운지 0.800 · 회의실 0.877 (학습 공간 대비 −6%p 이내, 일정 정답 학습 시 회의실 0.278)
노쇼 / 예약 없는 사용	실제 3건 모두 찾음(정밀도 0.75) / 3건 모두 찾았으나 정밀도 0.30
실데이터 실습실 후보	노쇼·휴강 8회(2장 CO2 기준과 6회 일치), 수업 없는 날 사용 6일(5일 일치)

측정 조건 — 합성: 위와 같은 분할, 노쇼·예약 없는 사용은 검증+시험 주(10-05~18), 회의실 예약 18건. 노쇼 정답은 예약 시작 후 15분 실제 인원 0(CO2 반응 지연을 고려해 판정은 20분). 실데이터: 실습실 2026-09-01~10-22, 합성으로 학습한 분류기 적용. 젯슨 25W.

- **일정 기반 정답은 틀린다:** 관찰 정답으로 학습하면 F1 0.705 → 0.919, 처음 보는 공간에서도 버틴다. 일정을 입력에 넣으면 일정표를 베껴 F1이 0.663으로 떨어진다(정답 누수).
- **가장 많이 틀리는 상황:** 사람이 막 들어온 직후 15분(오류율 88.8%) — CO2가 쌓이는 데 10~15분 걸린다. 환기 경보 헛경보는 CO2가 875ppm 근처에서 멈춘 경우다. 정확도는 "경보 없음"이 가장 높아 의미가 없다.
- **행동:** 일부 시간대라도 직접 관찰을 모으고, 예약 없는 사용은 경보가 아닌 확인 후보로 쓴다. 재현율 85.2%는 아슬아슬해 실데이터로 다시 확인한다.

6. 사전학습 모델 비교

확인 기준: ① 기준선·직접 학습 모델·사전학습 모델을 같은 시점에서 비교 ② 정확도·예측 구간 적중률·추론 시간·메모리로 판단 → **충족** (2,028개 동일 시점, 네 가지 모두 측정)

추가 학습 없이 쓴 Chronos-Bolt-small(파라미터 4,772만)은 60분 뒤 CO2에서 "현재값 유지"와 비슷했고, 시간표를 아는 GRU(3만)가 가장 정확했다. 일정을 함께 받는 Chronos-2는 강의실에서 GRU를 따라잡았지만 수천 배 느렸다. 채택: GRU.

방법 (같은 2,028개 시점)	5분	15분	30분	60분	60분 강의실A	10~90% 구간 적중률(60분)
GRU (과제 3)	7.0	10.8	**14.6**	**20.4**	21.2	— (값 하나)
Chronos-Bolt, 과거 2시간	7.1	13.3	23.5	39.3	—	81.9%
Chronos-Bolt, 과거 1일	7.5	12.7	20.6	34.4	37.2	75.5%
Chronos-Bolt, 과거 2일	7.8	12.5	19.7	32.0	—	72.0%
(심화) Chronos-2, CO2만 (1일)	6.6	10.6	17.4	29.1	29.3	75.5%
(심화) Chronos-2 + 일정·온습도 (1일)	6.6	10.9	17.3	26.2	**20.7**	75.1%
(심화) GRU + Bolt 반반	6.6	10.9	16.4	25.2	26.1	—
현재값 유지	7.6	13.7	21.2	33.7	37.5	—

비용 (젯슨 CPU, 공간 1곳 1회 평균 / 느린 5%): GRU 20 / 39ms·추가 메모리 +5.4MB·파라미터 32,344개, Chronos-Bolt 173 / 234ms·+197MB·47,718,016개, Chronos-2+일정은 시점당 371ms.

측정 조건 — 합성 데이터, 시험 2026-10-12~18 중 15분마다 고른 2,028개 시점(4공간), 모든 방법 같은 시점, CO2 MAE(ppm). Chronos는 추가 학습 없음(amazon/chronos-bolt-small, amazon/chronos-2). 일정 공변량: 과거 = 온도·습도·일정·시각·근무일, 미래 = 일정·시각·근무일. 섞기 가중치를 검증 주(10-05~11)에서 고르면 GRU 100%. 젯슨 25W, CPU 4스레드, 워밍업 5회 후 50회. 이 표의 GRU 20.4는 시점 부분집합 기준이라 3장(16.0)과 다르다.

- **차이의 원인은 일정 정보:** Chronos-2에 일정을 주자 강의실A가 29.3 → 20.7로 GRU(21.2) 수준이 됐고, 일정이 약한 라운지·회의실은 그대로였다. Bolt는 거의 모든 경우 GRU보다 나빠 섞기도 이득이 없었다.
- **구간·메모리:** 10~90% 구간은 72~82%가 맞아 이상(80%)에 가깝다. Chronos +197MB는 로컬 LLM과 함께 올리기에 GRU(+5MB)보다 불리하다.
- **채택:** 주 예측은 GRU(더 정확·8배 빠름·1,500배 작음). Chronos는 데이터 없는 새 공간의 초기 예측(일정 연결 시 Chronos-2)과 예측 구간이 필요할 때만. 합성은 시간표가 항상 맞아 GRU에 유리하다는 한계가 있다.

7. 엣지 최적화

확인 기준: ① 변환 후 CO2 예측 차이 1ppm 이하 ② 분류 결과가 바뀐 비율 0.1% 이하 ③ 측정 조건(전력 모드·클럭·반복·워밍업) 기록 → **충족** (TensorRT FP32 0.294ppm, 분류 0.0%. FP16은 재빌드 때 1.254ppm으로 미달 → FP32 배포)

GRU를 TensorRT로 변환했지만, 가장 빠르고 가벼운 것은 CPU의 ONNX Runtime이었다(0.13ms, 결과 차이 0.000ppm, 모델 4개를 함께 올려도 65MB). TensorRT FP16은 엔진을 다시 만들자 최대 차이가 1.254ppm으로 기준(1ppm)을 넘어, FP32(0.294ppm, 같은 속도)로 배포한다. 분류기는 변환 후 판단이 바뀐 비율 0.0%다.

예측 GRU	공간 1곳 평균 / 느린 5%	공간 4곳 평균	원래와 최대 차이	전력 증가 (1곳)	GPU 사용
PyTorch CPU (기준)	8.72 / 12.26 ms	8.44 ms	—	+2.1 W	0%
PyTorch GPU	0.93 / 1.04 ms	0.99 ms	0.002 ppm	+0.9 W	6~7%
ONNX Runtime (CPU)	**0.13 / 0.15 ms**	0.28 ms	**0.000 ppm**	+0.9 W	0%
TensorRT FP16 (첫 엔진)	0.75 / 0.87 ms	0.74 ms	0.564 ppm ✅	+1.3 W	35%
TensorRT FP16 (클럭 고정, 재빌드)	0.71 / 0.74 ms	0.71 ms	1.254 ppm ❌	+1.1 W	37%
TensorRT FP32	0.67~0.74 ms	0.68~0.73 ms	0.294 ppm ✅	+0.8~1.3 W	38~41%
(심화) ONNX Runtime INT8	0.13 / 0.14 ms	0.28 ms	7.479 ppm ❌	+0.8~1.0 W	0%

측정 조건 — 합성 데이터 시험 주 2026-10-12~18 전체(6,848개 시점)의 최악 차이. 젯슨 Orin Nano Super, 전력 모드 25W, 클럭 고정 안 함(표시한 행만 jetson_clocks), CPU 4스레드, 워밍업 20회 후 최소 200회·3초 반복, 입출력 복사 포함. 전력·GPU는 tegrastats 0.1초 간격(가만히 있을 때 5,818mW). 수집기·서비스 동시 가동. TensorRT 10.16.2, PyTorch 2.14.1.

분류기·메모리: 분류기 2개(공간 1곳)는 scikit-learn 1.49·2.97ms → ONNX Runtime 0.25·0.33ms, 판단이 바뀐 비율 0.0%. (심화) 모델 4개를 동시에 올리면 ONNX Runtime CPU 65MB / GRU만 TensorRT 1,081MB / 지금 서비스(PyTorch) 457MB → 사용 가능 5.4GB에서 3B급 4비트 LLM(약 2.3GB)은 여유, 7~8B급(약 5GB)은 부족.

측정 조건 — 분류기는 위와 같은 합성 시험 주. 메모리는 방식마다 새 프로세스에서 배치 4로 1회 추론한 직후 RSS(psutil), 보드 전체 7,486MB·사용 가능 5,436MB(수집기·서비스 가동 중), 25W, 2026-10-22. LLM 크기는 가중치 + 문맥 2~4k 기준 대략치.

- **GPU가 느린 이유:** 모델이 작아 계산보다 CPU↔GPU 복사·실행 준비(약 0.7ms)가 길다. 공간이 수십 개로 늘면 GPU가 역전할 것이다. FP16은 엔진마다 고르는 커널이 달라 오차가 흔들렸다 → FP32 배포, 배포마다 재측정.
- **행동:** 메모리를 먹는 것은 모델(0.5MB)이 아니라 PyTorch·CUDA다. 시계열 모델은 ONNX Runtime(CPU)으로 바꿔(메모리 약 −400MB, 70배 빠름) GPU는 3B급 로컬 LLM에 양보한다. INT8은 속도 이득 없이 오차만 커져 쓰지 않는다.

8. 상시 추론 서비스

확인 기준: ① 12시간 무중단 가동 ② 수집기를 10분 멈추면 '데이터 끊김' 경보, 다시 켜면 정상 ③ 조회 API로 공간별 예측·이상·상태 ④ 결과 형식 문서 → **충족** (17.5시간, 끊김 경보·복구, API 응답, 결과 형식 문서 작성)

예측 서비스 v1이 17.5시간 동안 1,052번 주기 중 한 번도 빠지거나 실패하지 않았고, 수집기를 멈추자 10분 뒤 "데이터끊김" 경보, 다시 켜자 1~2분 만에 정상으로 돌아왔다. 조회 API: `http://172.24.106.169:8080`. 매분 공간마다 ① 60분 예측과 "몇 분 뒤 1,000ppm 초과" ② 이상 여부·점수·원인 센서·규칙 경보 ③ 사용 여부·환기 선제 경보를 계산해 MQTT(보관 발행)와 조회 API로 내보낸다.

확인 기준	결과
12시간 무중단	✅ 17.5시간, 빈 분 0, 계산 오류 0, MQTT 발행 100%, 처리 평균 409ms(느린 5% 967ms)
수집기 10분 정지 → 끊김 경보 → 복구	✅ 실습실 15:42 경보 → 15:47 해제, 사무실 15:43 → 15:48, 회의실(10분 센서) "데이터부족" → 15:57
조회 API·형식 문서·재부팅	✅ `/state` · `/forecast` · `/selfcheck`, 결과 형식 문서(토픽·필드·단위·예시), systemd enabled·Restart=always
경보 (시작/계속/해제)	데이터끊김 2/0/2, 이상점수 29/11/27, 환기선제경보 3/0/3

측정 조건 — 실데이터(라이브 MQTT, 센서 3개), 가동 2026-10-21 15:21 ~ 10-22 08:52(17.5시간), 장애 시험 10-21 15:32~15:46 수집기 정지. 모델은 합성 데이터로 학습한 GRU·분류기. 젯슨 25W, PyTorch CPU, 매분 1초 계산.

심화: 예측으로 환기 제어 (환기 2배 가정)	사무실	실습실	회의실	1,000ppm 초과 합계	감소율	환기 강화 시간
없음 (실제 기록)	870분	500분	605분	1,975분	—	0분
뒤늦게 (지금 ≥1,000이면 켬)	90	25	315	430	78.2%	1,175
예측 (30분 안 ≥1,000 예측이면 켬)	**60**	**20**	**295**	**375**	**81.0%**	1,260
(참고) 예측, 환기 1.5배 / 3배 가정				865 / 330	56.2% / 83.3%	1,700 / 760

측정 조건 — 실데이터 시험 주 2026-10-14~21(5분 칸 2,304개 × 3곳), 실데이터로 학습한 GRU. CO2 물질 수지 모형(다음 CO2 = 지금 + 5분 × (발생량 − 환기율 × (지금 − 바깥))), 평소 환기율은 학습·검증 기간 밤 감소 속도(0.45~0.84/시간), 발생량은 실제 기록에서 거꾸로 계산. 환기 강화 배수는 설비를 확인하지 않은 가정. 젯슨 25W.

심화: 스스로 채점. 서비스가 30·60분 뒤 예측을 기억했다가 그 칸이 다 차면 채점하고, 같은 시점 '현재값 유지'와 비교한다. 최근 24번의 60분 오차가 현재값 유지보다 10% 넘게 크거나 24시간 평균의 2배를 넘으면 '예측성능저하' 경보를 보낸다(`/selfcheck` , 2026-10-22 13:40경 가동). 가동 직후 회의실에서 30분 예측 오차 455.7ppm(현재값 유지 376.2ppm, 8번 채점)이 기록됐는데, 그때 회의실은 예약 정보 없는 회의로 CO2 1,330ppm이었다. 두 방법이 함께 틀린, 예측할 수 없는 사건이다.

- **설계:** 학습 코드의 전처리 함수·정규화 값을 그대로 쓰고(다르면 예측이 조용히 틀려짐) 끝난 5분 칸만 쓴다. 공간 단위 실패 격리·주기 단위 재시도·systemd 재시작, 경보는 시작·해제와 30분마다 "계속"만 보내 77건으로 줄였다.
- **한계와 행동:** 합성 데이터 모델이라 이상점수 경보가 29번 났다 → 실데이터 모델 교체, 경보에 켜기 6 / 끄기 4 간격, ONNX Runtime 전환, 회의실 예약 연동. 예측 제어의 추가 이득(+3%p)은 환기 능력이 약할수록 커지고, 회의실(최고 2,874ppm)은 환기만으로는 부족해 인원 안내가 필요하다.

9. 종합

- **가장 의외였던 발견:** ① 4,772만 파라미터 사전학습 모델(32.0ppm)이 "지금 값 그대로"(33.7)를 거의 못 이기고 시간표를 아는 3만 파라미터 GRU(20.4)가 이겼다. 일정을 주자 Chronos-2도 강의실에서 GRU 수준이 됐다(6장). ② 합성 데이터는 성능을 4배 가까이 부풀렸다(59% vs 15%, 3장). ③ GPU 전용 엔진이 CPU보다 6배 느렸다(7장).
- **공정한 평가:** 시간순 분할, 정규화·임계값·모델 선택·가중치는 학습·검증 기간만, 모든 비교는 같은 시점, 사용 여부 입력에서 일정 제외, 고장 구간은 예측 학습·평가에서 제외.
- **한계:** 과제 4~7 주 실험은 합성 데이터, 환기 제어 효과는 가정한 계산, 가동 중 서비스는 아직 합성 모델, 브로커 재시작은 미시험.